

사전학습 언어모델 기반 혐오 표현 자동 필터링 시스템 제안 연구

최현우[○], 김수현^{*}

[○]순천향대학교 컴퓨터소프트웨어공학과

^{*}순천향대학교 컴퓨터소프트웨어공학과

e-mail:ihyonoo0520@gmail.com[○], kimsh@sch.ac.kr^{*}

A Study Proposing an Automatic Hate Speech Filtering System Based on Pre-trained Language Models

Hyun-Woo Choi[○], Su-Hyun Kim^{*}

[○]Dept. of Computer Software Engineering, Soonchunhyang University

^{*}Dept. of Computer Software Engineering, Soonchunhyang University

요 약

온라인 환경에서는 무분별한 혐오 표현이 빠르게 확산되기 쉽고, 사용자가 혐오 표현에 반복적으로 노출될 경우 부정적인 영향을 미칠 수 있다. 따라서 본 연구는 온라인 환경에서 발생하는 혐오 표현을 선제적으로 탐지하고 필터링하는 시스템을 제안한다. 제안 시스템은 텍스트 입력을 대상으로 다중 레이블 분류 기법을 적용하여 출신, 외모, 정치성향, 종교, 인종 등 다양한 유형의 혐오 표현을 정교하게 판별한다. 이를 위해 KoELECTRA 기반 사전학습 언어모델을 fine-tuning 하여 분류 성능을 높였으며, 탐지된 문장은 모자이크 형태로 필터링되며, 사용자가 열람을 원하는 경우 클릭을 통해 내용을 확인할 수 있는 선택적 노출 방식을 제공한다. 이는 표현의 자유를 직접적으로 제한하지 않으면서도, 사용자 보호 기능을 강화하기 위함이다. 제안된 시스템은 뉴스 댓글, 온라인 커뮤니티 등 온라인 플랫폼에서 발생하는 혐오 표현을 실시간으로 탐지하고 차단하는 데 활용될 수 있으며, 사용자 경험을 해치지 않으면서도 안전한 온라인 환경 조성에 기여할 수 있음을 시사한다.

키워드 : 혐오 표현(Hate speech), 필터링(Filtering), 선택적 노출(Selective exposure), 사전학습 언어모델(Pre-trained Language Models), 다중 레이블 분류(Multi-Label Classification), KoELECTRA

I. 서론

인터넷 이용률은 초기 보급 단계부터 현재까지 지속적으로 상승해 왔으며, 이에 따라 온라인 콘텐츠 접근성도 크게 확대되었다[1]. 따라서 현대 사회에서는 남녀노소 뉴스 댓글, 온라인 커뮤니티 등 다양한 플랫폼에서 생성되는 텍스트 정보를 손쉽게 열람할 수 있다. 특히 모바일 기기의 보편화로 인해 연령과 관계없이 타인의 표현을 실시간으로 접하는 환경이 자연스럽게 형성되었다.

그러나 이러한 디지털 환경은 혐오 표현, 욕설, 비속어와 같은 부적절한 언어에 노출되는 문제가 빈번하게 발생한다[2-3]. 특히 익명성을 기반으로 한 온라인 플랫폼의 구조는 사용자가 자신의 발언에 대한 책임을 느끼지

않게 만들기 때문에, 오프라인보다 더 부적절한 언어 사용을 유발한다[4]. 부적절한 언어는 모든 사용자에게 심리적 불쾌감을 유발할 수 있지만, 아동·청소년이 부정적 표현에 반복적으로 노출되는 경우 정서 안정성 저하나 부적절한 언어 습득 등 부정적 결과로 이어질 가능성이 제기되고 있다[5]. 물론 이는 아동·청소년에게만 국한된 문제가 아니라, 온라인 공간을 이용하는 모든 사용자에게 적용될 수 있는 보편적인 위험 요소이기도 하다.

따라서 혐오 표현을 자동으로 탐지하고 사용자가 혐오 표현에 노출되지 않도록 보호하는 기술적 장치가 필요하다. 본 연구는 이러한 필요성에 기반하여 혐오 표현 자동 필터링 시스템을 제안하며, 온라인 환경에서 안전하고 쾌적한 사용자 경험을 제공하는 것을 목표로 한다.

※ 본 연구는 2025년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업의 연구 결과로 수행되었음 (2021-0-01399)

II. 관련 연구

2.1 딥러닝 기반 자연어 처리 모델 연구

기존 순환 신경망 기반 모델은 긴 문맥 정보를 처리하는 데 한계를 보였으며, 이러한 제약을 극복하기 위해 자체적으로 문맥을 파악하는 Self-Attention 기반의 Transformer 구조가 등장하였다. Transformer 구조의 등장 이후 BERT(Bidirectional Encoder Representations from Transformers)와 ELECTRA(Efficiently Learning an Encoder that Classifies Token Replacements Accurately) 기반 모델이 문장 분류, 감성 분석, 문맥 이해 등 다양한 분야에서 준수한 성능을 보이고 있다[6-7]. 이러한 모델들은 대규모 코퍼스로 사전학습을 수행하여 문장 내 의미적·구문적 정보를 효과적으로 학습한다.

한국어 처리를 위해 개발된 KoBERT(Korean BERT), KR-BERT(Korean-specific BERT), KoELECTRA(Korean ELECTRA) 등은 한국어 어휘 구조의 특성을 반영하여 영어 기반 모델 대비 한국어 데이터에 대하여 우수한 성능을 보인다. 특히 KoELECTRA는 생성된 가짜 토큰을 판별하는 방식으로 학습을 진행하므로 MLM(Masked Language Modeling)에 비해 훨씬 효율적으로 파라미터를 업데이트할 수 있다. 이러한 구조적 특성은 적은 학습량에서도 학습 성능을 확보할 수 있는 장점을 제공한다. 앞선 방식들은 본 연구에서 KoELECTRA 기반 분류 모델을 채택한 타당성을 뒷받침할 수 있다.

2.2 한국어 혐오 표현 탐지 연구

한국어 혐오 표현 탐지 분야에서는 KoBERT, KR-BERT, KoELECTRA 등 한국어 특화 사전학습 언어모델을 활용하여 높은 성능을 달성한 연구들이 보고되고 있다. 특히 K-MHaS(Korean Multi-label Hate Speech)와 같은 다중 레이블 한국어 혐오 발언 데이터셋이 공개되면서, 단일 레이블 분류뿐 아니라 다중 레이블 기반 혐오 유형 탐지 연구가 확장되고 있다[8]. 앞선 방식은 온라인 환경에서 발생하는 복합적인 형태의 혐오 표현을 더 정확하게 탐지할 수 있는 기반을 제공한다.

하지만 기존 연구는 탐지 모델의 분류 성능을 향상하는 데 주력해 왔다는 한계가 있다. 혐오 표현이 탐지된 이후 해당 콘텐츠를 사용자에게 어떤 방식으로 제시되어야 하는지에 대한 고려는 부족하였다.

2.3 텍스트 기반 유해 콘텐츠 필터링 연구

기존 텍스트 기반 유해 콘텐츠 필터링 연구들은 특정 단어를 삭제하거나 특정 문자를 다른 문자로 치환하는 방식이 일반적이었다[9]. 그러나 이러한 방식은 콘텐츠를 훼손하고, 문장의 의미가 왜곡되거나, 과도한 차단으로 인해 검열 논란을 제기될 수 있다는 문제가 있다.

III. 제안방법

3.1 제안 시스템 개요

앞선 연구[8] 혐오 표현이 탐지된 이후 해당 콘텐츠를 사용자에게 어떤 방식으로 제시해야 하는지에 대한 고려는 부족하였고, 앞선 연구[9]는 콘텐츠를 훼손하고, 문장의 의미가 왜곡되거나, 과도한 차단으로 인해 검열 논란을 제기될 수 있다는 문제가 있었다.

본 연구는 사용자의 선택적 열람을 허용하는 혐오 표현 자동 필터링 시스템을 제안한다. 이는 부적절한 문장을 자동으로 가리되, 사용자가 필요시 내용을 열람할 수 있도록 하여, 사용자 보호와 표현의 자유 사이의 균형을 달성하는 접근이다.

3.2 데이터 활용

본 연구에서는 온라인 환경에서 발생하는 한국어 혐오 표현을 분석하기 위해 K-MHaS 데이터셋을 사용하였다. 해당 데이터셋은 Lee et al.[8]가 한국어 온라인 혐오 표현의 정량적 분석을 목적으로 구축한 공개 데이터셋으로, 수집 과정에서 개인정보 및 민감 정보는 모두 제거하여 연구 윤리를 준수하였다.

K-MHaS는 국내 온라인 뉴스 댓글에서 발췌한 109,692개의 문장으로 구성되어 있으며, 각 문장은 다중 레이블 구조로 분류된다. 레이블은 Politics(정치성향차별), Origin(출신차별), Physical(외모차별), Age(연령차별), Gender(성차별), Religion(종교차별), Race(인종차별), Profanity(혐오욕설), Not Hate Speech(해당 없음)의 총 9개 범주로 구성되며, 하나의 문장이 둘 이상의 혐오 요소를 동시에 포함할 수 있도록 설계되어 있다.

K-MHaS는 데이터셋의 신뢰성을 확보하기 위해 별도의 레이블링 가이드를 마련하고, 해당 가이드를 기반으로 다수의 전문 데이터 레이블러가 레이블링을 수행하였으며, 불일치가 발생한 문장은 교차 검수를 통해 최종 레이블이 확정되었다. 레이블링 품질 검증을 위해 레이블러 간 일치도를 측정한 결과 평균 0.89(0~1 범위에서 산출) 수준으로 나타나, 데이터셋의 레이블 일관성과 안정성이 충분히 확보되었음을 확인하였다.

가이드는 명시적 혐오 표현뿐 아니라 풍자·비유를 통해 드러나는 암시적 혐오 표현까지 포함하도록 설계되어 있으며, 개별 단어가 아닌 문장의 전체 의미와 맥락을 기준으로 혐오 여부를 판단한다.

K-MHaS는 다양한 온라인 플랫폼에서 나타나는 구어체·비표준 표현 등을 폭넓게 포함하고 있어 실제 온라인 환경을 잘 반영한다. 이는 혐오 표현의 세부 유형을 정교하게 구분하고, 모델의 일반화 성능을 평가하는 데 적합하므로, 본 연구의 학습 데이터로 활용하였다.

3.3 데이터 분석 모델 선정

협오 표현 탐지 모델 선정에 앞서, 본 연구와 유사한 한국어 텍스트 분류 환경에서 수행된 선행 연구를 검토하였다. Lee et al.[8]은 표 1과 같이 한국어 온라인 텍스트를 대상으로 MultiBERT, KoELECTRA, KoBERT, KR-BERT 사전학습 언어모델을 비교·분석하였다.

표 1. 대표적인 사전학습 NLP 모델

모델명	사전학습 데이터
MultiBERT	104개 언어 Wikipedia (매개변수 110M, 어휘 119K)
KoELECTRA	Wikipedia, 뉴스, 나무위키, Modu (매개변수 14M, 어휘 35K)
KoBERT	Wikipedia (매개변수 92M, 어휘 8K)
KR-BERT	Wikipedia, 뉴스 (매개변수 99M, 16K)

비교·분석 결과 KoELECTRA가 다른 모델 대비 동일한 데이터와 실험 조건에서 F1-score, AUC(Area Under the Curve), E.M.(Exact Match) 등 주요 성능 지표에서 가장 우수한 분류 성능을 기록하였다.

특히 한국어 협오 표현 탐지와 같이 문맥 의존성이 강한 문장 분류 작업에서는 KoELECTRA가 다른 BERT 계열 모델 대비 안정적인 성능을 보이는 것으로 알려져 있다. 따라서 본 연구는 선행 연구와 동일한 한국어 온라인 텍스트 환경에서 높은 성능을 입증한 KoELECTRA 모델을 협오 표현 탐지 모델로 채택하였다.

3.4 시나리오

그림 1은 제안 시스템의 전체적인 시나리오이다.




그림 1. 제안 시스템 시나리오

3.5 개발 환경

표 2는 제안 시스템의 개발 환경이다.

표 2. 제안 시스템 개발 환경

개발 언어	딥러닝			UI
	딥러닝 프레임워크	데이터 전처리	사전학습 언어모델	
Python	Pytorch	Hugging Face	KoELECTRA	Streamlit

3.6 모델 학습 결과 분석

표 3은 Lee et al.[8]과 본 연구의 모델 성능을 비교한 결과이다.

표 3. 기존 연구와 본 연구의 모델 성능 비교

	F1-macro	F1-micro	F1-weighted	E.M.	AUC	H.L. (↓)
Lee et al. [8]	0.725	0.849	0.848	0.799	0.912	0.038
본 연구	0.714	0.826	0.823	0.825	0.962	0.025

본 연구에서는 KoELECTRA 기반 협오 표현 탐지 모델을 학습하여 성능을 평가하였다. 성능 평가는 F1-score(macro, micro, weighted), E.M., AUC, H.L.(Hamming Loss) 지표를 사용하였다. 각 지표는 모델이 협오 표현을 얼마나 정확하고 안정적으로 탐지하는지 측정하며, 이는 본 연구 제안 시스템의 신뢰성과 연결된다.

우선, F1-score는 정밀도(precision)와 재현율(recall)의 조화평균으로, 모델이 실제 협오 문장을 얼마나 정확히 찾아내고 놓치지 않았는지를 평가한다. 본 연구의 F1-macro=0.714, F1-micro=0.826, F1-weighted=0.823은 기존 연구 대비 약간 낮은 값이지만, 전반적으로 안정적인 성능을 보였다. 특히 F1-micro가 높다는 것은 모델이 다양한 협오 표현을 대상으로 일관된 탐지 성능을 확보하였음을 의미하며, 여러 유형의 협오 표현을 누락 없이 탐지하는 데 유리함을 의미한다.

E.M. 지표는 모델이 문장의 모든 레이블을 정확히 맞췄을 때만 정답으로 인정하는 엄격한 기준으로, 본 연구는 0.825로 기존 연구보다 높은 수치를 달성하였다. 이는 한 문장에 협오욕설·정치성향차별·출신차별 등 복수의 협오 요소를 포함하는 문장에서도 모델이 여러 레이블을 정확하게 예측할 수 있는 능력을 확보했음을 의미한다.

AUC 지표는 예측 점수의 분리 성능을 나타내는 지표로, 본 연구는 0.9621로 매우 높은 값을 기록하였다. 이는 모델이 결정 경계를 뚜렷하게 학습했다는 의미이다.

H.L. 지표는 전체 레이블 중 잘못 예측한 비율을 측정하며, 값이 낮을수록 모델의 오류율이 적다는 것을 의미한다. 본 연구는 0.025로 기존 연구보다 낮은 값을 보였다. 이는 모델이 안정적인 모델임을 의미한다.

종합하면 모델 성능은 기존 연구 대비 일부 F1-score는 소폭 낮지만, E.M., AUC, H.L.에서 더 우수한 결과를 보여 본 연구의 제안하는 시스템이 신뢰성과 실용성을 확보할 수 있었음을 시사한다.

3.7 시스템 실행 결과

그림 2는 작성자가 협오 표현이 포함된 문장을 입력했을 경우 시스템이 협오 표현을 탐지하여 필터링하는 화면을 보여준다. 예시 문장에서는 외모 차별과 출신 차별이 동시에 탐지되었으며, 이에 따라 필터링된 것을 확인

할 수 있다. 이를 통해 시스템이 단일 유형뿐 아니라 복합적인 유형도 정확하게 식별할 수 있음을 시사한다.




그림 2. 혐오 표현 필터링 결과

그림 3은 필터링된 문장을 클릭하여 선택적으로 열람한 화면이다. 기본적으로 혐오 표현이 포함된 문장은 사용자 보호를 위해 차단되지만, 필요시 사용자가 내용을 열람할 수 있도록 선택적 노출 기능을 제공한다.



그림 3. 혐오 표현 열람 결과

IV. 결론

본 연구에서는 온라인 환경에서 빈번하게 발생하는 혐오 표현 문제를 해결하기 위해, 사전학습 언어모델 기반 혐오 표현 자동 필터링 시스템을 제안하였다. 기존 연구들이 혐오 표현을 단순 탐지하는 데 초점을 두었던 것과 달리, 본 연구는 탐지 이후 단계에서 사용자가 원하지 않게 혐오 표현에 노출되는 것을 보호하는 기술적 시스템을 구현했다는 점에서 의의가 있다. 또한 사용자가 필요시 내용을 확인할 수 있는 선택적 노출 방식을 도입함으로써, 사용자 경험을 해치지 않으면서도 불쾌한 유해 콘텐츠 노출을 효과적으로 차단할 수 있음을 검증하였다.

본 연구에서는 한국어 온라인 뉴스 댓글로 구성된 K-MHaS 데이터셋을 활용하여 KoELECTRA 기반 혐오 표현 탐지 모델을 학습하였다. 실험 결과, F1-score, E.M., AUC 등 핵심 성능 지표에서 기존 연구 대비 더 우수한 성능을 기록하여, 다양한 유형의 혐오 표현을 신뢰도 높게 탐지할 수 있음을 확인하였다.

제안한 시스템은 뉴스 댓글, 온라인 커뮤니티 등 다양한 온라인 플랫폼에서 건강한 소통 환경 조성, 아동·청소년 등 민감 계층 보호, 사회적 갈등 완화, 인터넷 이용 환경 개선에 기여할 수 있는 잠재력을 가진다. 이는 단순한

분류 모델을 넘어 실제 서비스 환경에서 적용할 수 있는 실용적 기술로서 의미 있는 성과라고 평가된다.

그러나 본 연구에는 두 가지 한계가 존재한다. 첫째, 학습 데이터가 뉴스 댓글로 한정적이기 때문에 SNS·메신저에 대한 일반화 성능은 추가 검증이 필요하다. 둘째, 혐오 표현의 정의와 경계는 사회문화적 요인에 따라 변화하므로, 모델의 지속적인 업데이트가 요구된다.

향후 연구에서는 SNS·커뮤니티 등 다양한 도메인 데이터 확장, 메신저 기반 혐오 표현 탐지 모델 적용을 통해 시스템의 범용성과 정확성을 한층 강화할 계획이다.

참고문헌

- [1] 과학기술정보통신부 및 한국지능정보사회진흥원, “2024 인터넷이용실태조사”, March. 2025
- [2] 쿠키뉴스, “밈으로 소비된 혐오, 사회를 병들게 한다 [혐오의 시대③]”, 2025.6.2, <https://v.daum.net/v/20250602060106093>
- [3] 국민일보, “‘혐오 표현’에 불든 대한민국... 유튜브·소셜미디어가 확산 통로”, 2019.8.28, <https://www.kmib.co.kr/article/view.asp?arcid=0924095177>
- [4] 황병화, 이은규, “인터넷 커뮤니티에서의 익명성과 사용자의 단어사용 사이의 관계 분석 연구”, 한국통신학회논문지. Vol. 50, pp. 105-115, Jan. 2025
- [5] A.J. Kansok-Dusche, C. Ballaschk, N. Krause, A. Zeigler, L. Seemann-Herz, S. Wachs, and L. Bilz, “A Systematic Review on Hate Speech among Children and Adolescents: Definitions, Prevalence, and Overlap with Related Phenomena,” Trauma, Violence, & Abuse, Oct. 2023.
- [6] N. M. Gardazi, A. Daud, M. K. Malik, A. Bukhari, T. Alsahfi, and B. Alshemaimri, “BERT applications in natural language processing: a review,” Artificial Intelligence Review, vol. 58, no. 6, Feb. 2025.
- [7] S. Lee, H. Jang, Y. Baik, S. Park, and H. Shin, “KR-BERT: A Small-Scale Korean-Specific Language Model,” arXiv preprint arXiv:2008.03979, Aug. 2020.
- [8] J. Lee, T. Lim, H. Lee, B. Jo, Y. Kim, H. Yoon, and S. C. Han, “K-MHaS: A multi-label hate speech detection dataset in Korean online news comment,” arXiv preprint arXiv:2208.10684, Sep. 2022.
- [9] S. Jhaver, Q. Z. Chen, D. Knauss, and A. Zhang, “Designing word filter tools for creator-led comment moderation,” Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI '22), pp. 1-32, Apr. 2022.